MINERAÇÃO DE DADOS · UFU · COMPETIÇÃO KAGGLE

Detecção de Diabetes com dados tabulares

Limpeza, validação sem vazamento e um ensemble RF + ExtraTrees + HGB

Igor Oliveira Leandro Marques Adiel Pereira

O PROBLEMA

Controle (0) ou diabetes (1)?

Classificar cada paciente a partir de dados tabulares clínicos, numa base que mistura pacientes reais e artificiais.

540
pacientes no treino, 52% com diabetes

312
pacientes no teste, sem rótulo

F1
métrica da competição

3
avaliações: leaderboard público, privado e conjunto externo

Regra que guiou tudo: o teste não entra em nenhuma etapa do treino ou da validação. Ele só recebe a predição final.

OS DADOS

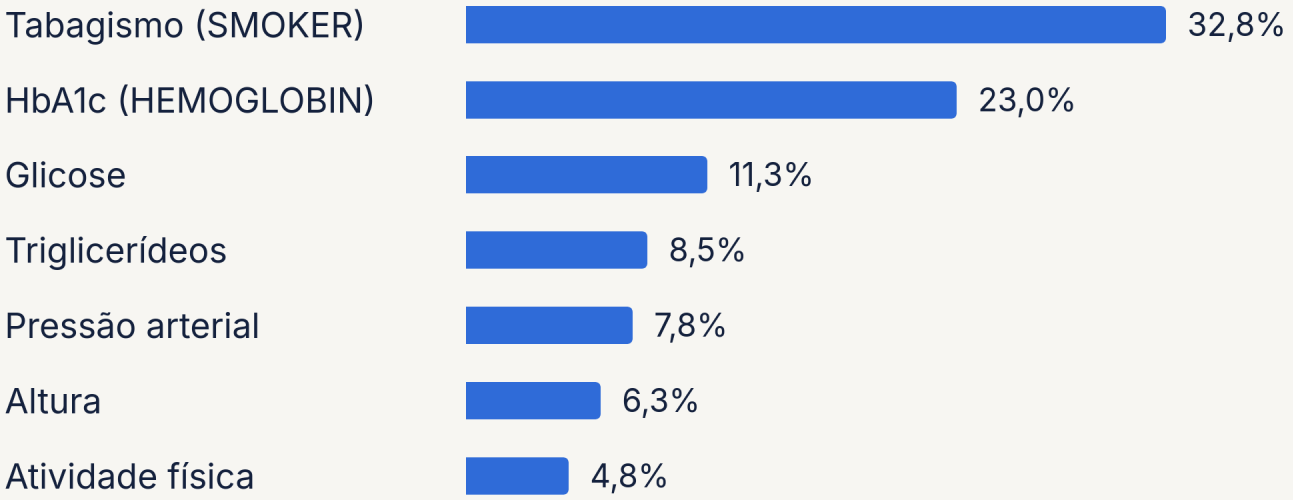
Uma base suja de propósito

Problema	Exemplo na base	Tratamento
Datas em 3 formatos	2018-02-23 · Jan 19 2021 · 17/02/2020	Ano extraído por regex → idade recuperada
Unidades misturadas	Altura 1.45 (m) e 170 (cm); glicose em mmol/L; HbA1c em mmol/mol	Conversão para cm, mg/dL e %
Texto inconsistente	MALE · f · FEMALE; No · YES · Não · 1; “Sedentary ”	Minúsculas e sem espaços: um rótulo por categoria
Valores impossíveis	Peso em libras (IMC até 84); idade 0	Peso convertido pelo IMC; idade recalculada

OS DADOS

O que falta e o que foi convertido

Faltantes no treino (% dos 540 pacientes)



Convertidos no treino

107
alturas de metros para centímetros

45
glicemias de mmol/L para mg/dL

44
HbA1c de mmol/mol para %

9
idades recalculadas pela data do exame

PRÉ-PROCESSAMENTO

Pipeline: tudo decidido só no treino

01

Conversão numérica

Uma coluna vira número só se ≥ 80% dos valores do treino forem numéricos.

02

Categorias

GENDER, SMOKER, FAMILY_HISTORY e PHYSICAL_ACTIVITY em minúsculas, sinônimos unidos.

03

Unidades e erros

m → cm, mmol/L → mg/dL, mmol/mol → %, libras → kg; idade 0 recalculada.

04

Novas features

PA sistólica e diastólica, IMC e RISK_SCORE (glicose > 100, IMC > 30, PA > 130).

05

Colunas

Dummies só com as categorias do treino; saem id, PATIENT_CODE, EXAM_DATE e BIRTH_YEAR.

06

Faltantes

−999 no RF e no HGB; mediana + indicador de faltante no ExtraTrees, KNN e MLP.

VALIDAÇÃO

Validação sem vazamento

5 × 3

folds × repetições: cada paciente do treino é previsto por um modelo que não o viu (OOF).

20

pacientes repetidos no treino ficam sempre no mesmo fold (StratifiedGroupKFold).

0

pacientes do teste aparecem no treino, conferido pelo PATIENT_CODE.

0,002

de F1 vale 1 paciente no OOF: diferença menor que isso é ruído.

MODELOS

Ponto de partida: KNN, Árvore e MLP

KNN

k = 15, ponderado pela distância; numéricas com QuantileTransformer e indicador de faltante.

AUC	F1
0,924	0,852

Árvore de Decisão

Profundidade máxima 6, mínimo de 10 pacientes por folha, peso 1,4 na classe 1.

AUC	F1
0,938	0,891

MLP

Camadas de 64 e 32 neurônios, early stopping, mesmo pré-processamento do KNN.

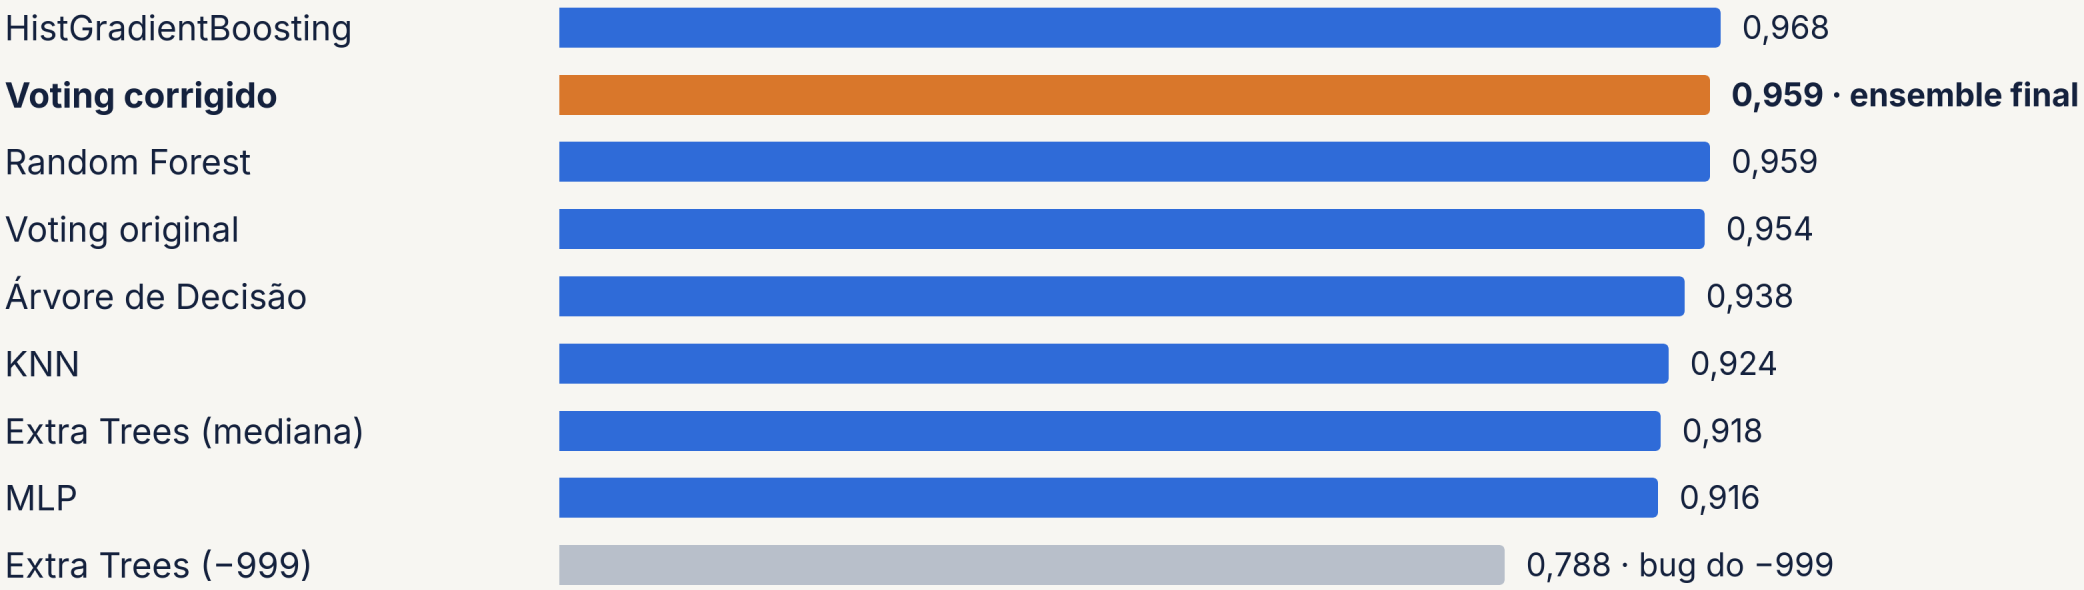
AUC	F1
0,916	0,850

OOF 5-fold só no treino · limiar 0,5 · melhor F1 entre os três em azul

MODELOS

Do ponto de partida ao ensemble

AUC no OOF (5-fold, só treino), quanto maior, melhor



Voting = Random Forest (peso 1,2) + ExtraTrees (1,2) + HGB (1,0), voto suave, classe 1 com peso 1,4, limiar 0,55

ACHADO

O −999 cegava o Extra Trees

Coluna HbA1c com faltante = −999: onde cai o corte sorteado



−999 (faltante) 4,6 a 13,1% (valores reais, em laranja)

O Extra Trees sorteia o corte entre o mínimo e o máximo da coluna: **99%** dos cortes caem entre −999 e 4,6 e só separam "faltante × não faltante".

AUC

0,788 → 0,918

F1

0,723 → 0,835

CORREÇÃO

mediana + indicador de faltante

CASOS DE FRONTEIRA

Três abordagens para os casos difíceis

01

Filtro de ruído

Brodley & Friedl (1999): sai do treino quem tem o rótulo contradito, com confiança ≥ 0,8, pela previsão out-of-bag de um Random Forest. Cerca de 2 pacientes por fold.

F1 no OOF (3× 5-fold)

0,911

02

Regra clínica (ADA)

Na faixa de dúvida do modelo (0,40 a 0,70) decide o critério médico: HbA1c ≥ 6,5% ou glicemia ≥ 126 mg/dL. Sozinho, ele acerta 94% dos casos que decide.

F1 no OOF (3× 5-fold)

0,909

03

Pesos focais + vizinhos

Casos difíceis do treino pesam até 5× no ajuste, com features de vizinhança (KNN) e limiar varrido de 0,480 a 0,580.

F1 no OOF (3× 5-fold)

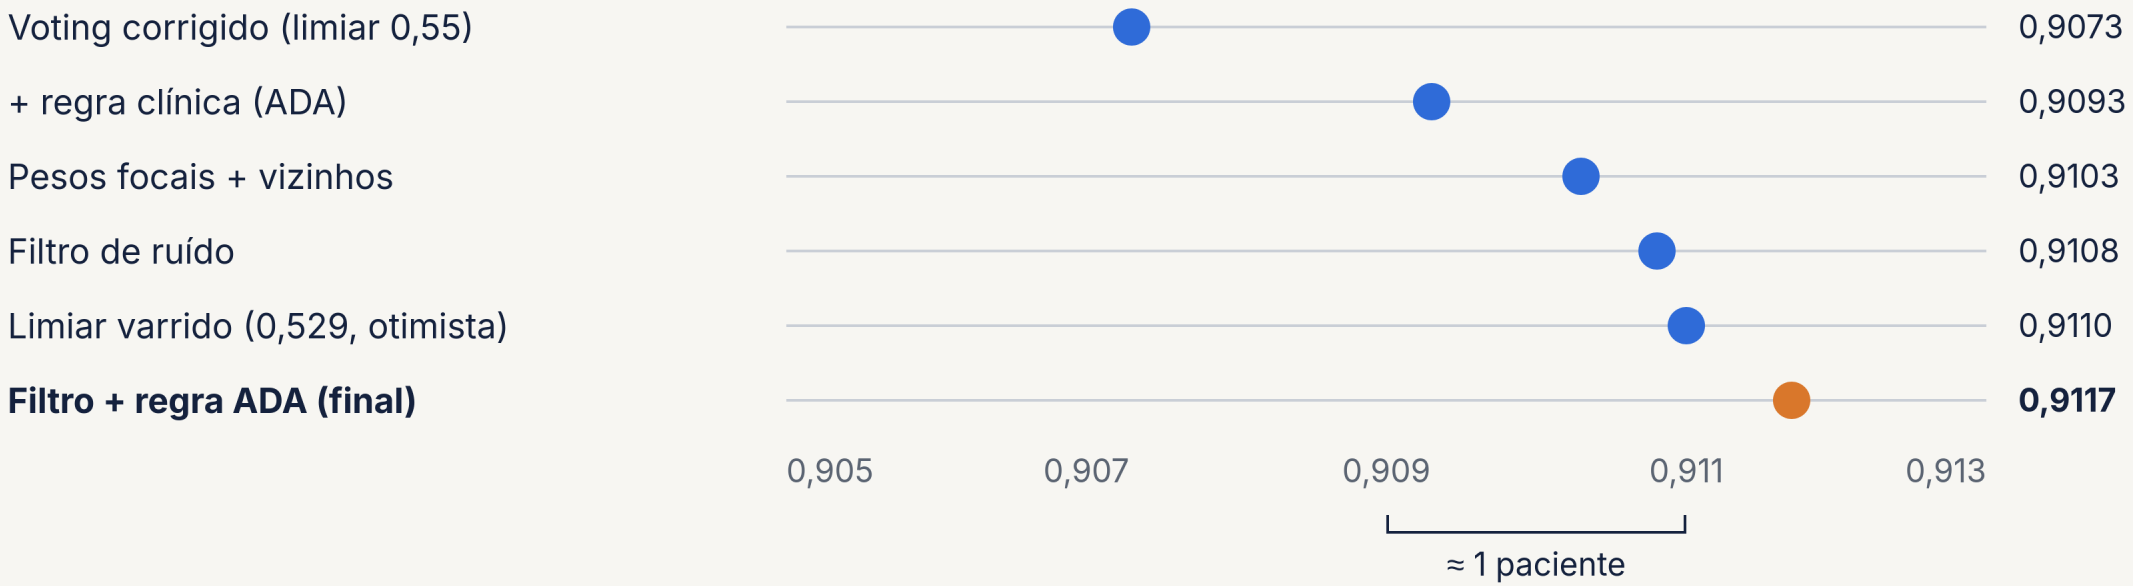
0,910

Base de comparação: Voting corrigido, F1 0,907 no limiar 0,55. Pesos, filtro e vizinhos são recalculados dentro de cada fold: o teste nunca entra.

CASOS DE FRONTEIRA

Todas convergem em ~0,911

F1 no OOF (3× 5-fold) · eixo ampliado de 0,905 a 0,913



Entre a pior e a melhor abordagem: cerca de 2 pacientes. O limite está nos dados, não no modelo.

RESULTADO

Modelo final

0,90822
melhor nota no Kaggle público (Voting, limiar 0,529)

0,899
Kaggle público do modelo final (submission.csv)

0,9117
F1 no OOF do modelo final (3× 5-fold, só treino)

Composição

- Limpeza corrigida
- ExtraTrees com mediana
- Filtro de ruído
- Regra clínica na fronteira
- Voting RF + ET + HGB
- Limiar 0,55

Baseline da disciplina no Kaggle: 0,87. Modelo final escolhido pelo diabetes_final.py no OOF, sem olhar o teste. As duas notas públicas diferem em uns 2 pacientes: ruído.

CONCLUSÕES

O que aprendemos

1. **Limpeza pesa tanto quanto o algoritmo:** um detalhe de imputação derrubava o ExtraTrees de 0,918 para 0,788 de AUC.

2. **Saber o tamanho do ruído:** com 540 pacientes, 1 paciente ≈ 0,002 de F1. Diferença menor que isso não é melhoria.

3. **O leaderboard público engana:** pseudo-rótulos tirados do leaderboard derrubaram a nota para 0,903. As decisões finais saíram só do OOF.

4. **O teto está nos dados:** três técnicas diferentes para os casos de fronteira convergiram em ~0,911.

DETECÇÃO DE DIABETES · MINERAÇÃO DE DADOS

Obrigado!

Igor Oliveira Leandro Marques Adiel Pereira